Clasificación de Pisos Térmicos de Colombia: Comparación de Cinco Algoritmos de Machine Learning con Validación por Ciudad y Control de Fuga de Información

Informe académico

Especialización en Análisis de Datos

Autor

Cristian Alejandro Perdomo Rivas

Asignatura: Machine Learning

17 de octubre de 2026

Resumen

El presente informe documenta el diseño, la implementación y la evaluación de un modelo de clasificación supervisada orientado a predecir el piso térmico (cálido, templado o frío) de registros climáticos diarios de ciudades colombianas. Se empleó un conjunto de datos reales obtenido de la API pública Open-Meteo (año 2023), conformado por 9 490 registros diarios de 26 ciudades. La variable objetivo se asignó a partir de la temperatura media diaria, por lo que las clases no representan necesariamente el piso térmico geográfico oficial, sino una etiqueta operativa del ejercicio. Se compararon cinco algoritmos (Árbol de Decisión, Random Forest, SVM, K-NN y Naive Bayes) bajo exactamente las mismas condiciones de entrenamiento y evaluación. Para prevenir la fuga de información, la partición entrenamiento/prueba se realizó por ciudad mediante *GroupShuffleSplit*, de modo que ninguna ciudad apareciera simultáneamente en ambos conjuntos, y el escalado se ajustó únicamente con los datos de entrenamiento. Los resultados indican que Random Forest obtuvo el mejor desempeño (F1 macro = 0,9290; exactitud = 0,9297), mientras que K-NN presentó el menor rendimiento (F1 macro = 0,7981). Se discuten las implicaciones metodológicas de la validación por grupos y la pertinencia de múltiples métricas en problemas multiclase.

Palabras clave: clasificación supervisada, pisos térmicos, fuga de información, validación por grupos, machine learning, Open-Meteo.

1 Introducción

Colombia, por su ubicación en la zona tropical y la presencia de la cordillera de los Andes, presenta una marcada variación climática asociada fundamentalmente a la altitud. Esta característica da origen a los denominados *pisos térmicos*, franjas altitudinales con rangos de temperatura relativamente homogéneos que condicionan la distribución de la vegetación, los cultivos y los asentamientos humanos (Instituto de Hidrología, Meteorología y Estudios Ambientales [IDEAM], 2023). En términos generales, se reconocen tres pisos principales: el cálido (temperatura media superior a 24 °C), el templado (entre 18 y 24 °C) y el frío (inferior a 18 °C).

La clasificación automática de estos pisos térmicos constituye un problema de *aprendizaje automático* de tipo supervisado, en el que un modelo debe aprender a asignar una etiqueta discreta a partir de un conjunto de características. Este tipo de tareas reviste interés tanto académico como aplicado, pues permite ilustrar conceptos fundamentales de la disciplina (selección de características, escalado, comparación de algoritmos y evaluación de modelos) sobre un dominio geográfico concreto y comprensible.

El objetivo del presente trabajo es comparar el desempeño de cinco algoritmos de clasificación sobre un conjunto de datos reales de temperatura media diaria de 26 ciudades colombianas, prestando especial atención a dos aspectos metodológicos de gran relevancia en la práctica: (a) la correcta construcción del problema de clasificación, distinguiendo la etiqueta operativa del concepto geográfico oficial de piso térmico; y (b) el control de la *fuga de información* (*data leakage*), un sesgo que infla artificialmente las métricas de evaluación cuando los datos de prueba contaminan el proceso de entrenamiento.

2 Marco conceptual

2.1 Fuga de información (*data leakage*)

La fuga de información se define como la situación en la que información del conjunto de prueba, que no estaría disponible en un escenario de despliegue real, se utiliza (directa o indirectamente) durante la construcción del modelo, produciendo estimaciones de rendimiento

optimistas y no generalizables (Kaufman et al., 2012). Dos fuentes habituales de fuga son relevantes para este estudio. La primera es el escalado de características: si el escalador se ajusta con todo el conjunto de datos (entrenamiento y prueba), las estadísticas de escala (media y desviación estándar) incorporan información de las observaciones de prueba. La segunda, y más sutil, es la *dependencia entre observaciones*: cuando los datos presentan una estructura de grupos (por ejemplo, múltiples registros diarios pertenecientes a una misma ciudad), una partición aleatoria por filas puede situar registros del mismo grupo en ambos conjuntos, permitiendo que el modelo *memorice* las propiedades del grupo y sea evaluado sobre observaciones casi idénticas a las que ya vio.

2.2 Validación por grupos

La validación por grupos (*grouped validation*) es una estrategia que garantiza que todos los registros de un mismo grupo queden en un único subconjunto (entrenamiento o prueba), evitando la fuga derivada de la dependencia entre observaciones (Raschka, 2018). En este trabajo, cada ciudad constituye un grupo, de manera que las observaciones diarias de una ciudad específica se asignan íntegramente a uno de los dos conjuntos.

3 Metodología

3.1 Datos

Se construyó un conjunto de datos a partir de la API pública del servicio meteorológico Open-Meteo, la cual no requiere clave de acceso y proporciona datos históricos de reanálisis. Para cada una de 26 ciudades colombianas (10 del piso cálido, 9 del templado y 7 del frío, definidas a priori según su altitud), se descargó la temperatura media diaria a 2 metros y la precipitación acumulada diaria durante el año calendario 2023. El conjunto resultante contiene 9 490 registros (día $\times$ ciudad), con las coordenadas (latitud y longitud) y la altitud (msnm) de cada ciudad como información geográfica constante por grupo.

3.2 Construcción de la variable objetivo

La variable objetivo (clase) se asignó a cada registro según su temperatura media diaria, aplicando los umbrales convencionales: *cálido* para temperaturas $\geq 24\,°\text{C}$, *templado* para temperaturas entre 18 y 24 °C y *frío* para temperaturas $< 18\,°\text{C}$. Es importante resaltar que, por esta definición, la clase depende del dato puntual de temperatura del día y, por consiguiente, **no coincide necesariamente con el piso térmico geográfico oficial** de la ciudad, sino que constituye una etiqueta operativa construida para efectos del ejercicio de clasificación. La distribución resultante fue la siguiente: 3 835 registros cálidos (40,4 %), 2 367 templados (24,9 %) y 3 288 fríos (34,6 %).

3.3 Características de entrada

Para evitar la trivialización del problema, la temperatura no fue incluida entre las características predictoras. Se emplearon seis variables: latitud, longitud, altitud, mes, día del año y precipitación acumulada (mm). De esta manera, el modelo debe inferir el piso térmico a partir de información geográfica y temporal, en lugar de leer directamente la temperatura que define la etiqueta.

3.4 Técnica de muestreo y preprocesamiento

La partición se realizó mediante `GroupShuffleSplit` de *scikit-learn*, asignando el 80 % de las ciudades al entrenamiento (20 ciudades) y el 20 % a la prueba (6 ciudades), con semilla fija (`random_state = 42`). La verificación del procedimiento confirmó que **ninguna ciudad aparece simultáneamente** en ambos conjuntos (0 ciudades compartidas). Las seis ciudades de prueba fueron Armenia, Florencia, Ibagué, Manizales, Pasto y Valledupar. Posteriormente, las características se estandarizaron con `StandardScaler`, ajustando el escalador **únicamente** con los datos de entrenamiento y aplicando la transformación a ambos conjuntos.

3.5 Algoritmos

Se entrenaron y evaluaron cinco algoritmos de clasificación bajo exactamente las mismas condiciones de datos:

1. **Árbol de Decisión**, con profundidad máxima de 5 para limitar el sobreajuste.
2. **Random Forest**, con 100 árboles y profundidad máxima de 8.
3. **Máquina de Vectores de Soporte (SVM)**, con kernel radial (RBF), $C = 1{,}0$ y $\gamma =$ `scale`.
4. **K-Vecinos más Cercanos (K-NN)**, con $k = 5$.
5. **Clasificador Bayesiano Ingenuo (Naive Bayes) gaussiano**.

3.6 Métricas de evaluación

Dado el carácter multiclase del problema, se calcularon la exactitud (*accuracy*), la precisión (*precision*), la sensibilidad (*recall*) y el F1-score, reportando los promedios *macro* y *weighted*. El promedio macro otorga el mismo peso a cada clase con independencia de su tamaño, lo que resulta adecuado para un problema con clases desbalanceadas. La métrica de referencia para la comparación global fue el F1-score macro, por considerarse el indicador más equilibrado cuando se desea un único valor resumen.

4 Resultados

4.1 Rendimiento comparativo

La Tabla 1 resume el desempeño de los cinco algoritmos, ordenados de mayor a menor F1-score macro.

Cuadro 1: *Comparación del desempeño de los cinco algoritmos de clasificación evaluados sobre el conjunto de prueba (ciudades no vistas durante el entrenamiento).*

Modelo	Accuracy	Precisión (macro)	Recall (macro)	F1-score (macro)
Random Forest	0,9297	0,9283	0,9315	0,9290
Naive Bayes	0,9256	0,9276	0,9299	0,9263
Árbol de Decisión	0,8963	0,9032	0,9034	0,8977
SVM	0,8813	0,8927	0,8898	0,8833
K-NN	0,7945	0,8306	0,8106	0,7981

El mejor modelo fue **Random Forest**, con un F1-score macro de 0,9290 y una exactitud de 0,9297, mientras que **K-NN** presentó el menor rendimiento (F1 = 0,7981). La diferencia de F1-score macro entre el mejor y el peor modelo fue de 0,1309.

4.2 Desempeño por clase

La Tabla 2 presenta el reporte de clasificación desagregado por clase para cada modelo.

Cuadro 2: *Reporte de clasificación por clase (precisión, recall y F1-score) para cada algoritmo evaluado.*

Modelo	Clase	Precisión	Recall	F1	Soporte
Árbol de Decisión	Cálido	0,92	1,00	0,96	668
	Templado	0,80	0,91	0,85	703
	Frío	1,00	0,80	0,89	819
Random Forest	Cálido	0,92	1,00	0,95	668
	Templado	0,90	0,88	0,89	703
	Frío	0,97	0,92	0,94	819
SVM	Cálido	0,92	1,00	0,96	668
	Templado	0,76	0,91	0,83	703
	Frío	1,00	0,76	0,86	819
K-NN	Cálido	0,94	0,99	0,96	668
	Templado	0,63	0,89	0,73	703
	Frío	0,92	0,56	0,70	819
Naive Bayes	Cálido	0,93	0,99	0,96	668
	Templado	0,85	0,93	0,89	703
	Frío	1,00	0,87	0,93	819

4.3 Matrices de confusión

Las matrices de confusión de los cinco modelos se presentan en la Tabla 3. En todas ellas, las filas corresponden a la clase real y las columnas a la clase predicha, siguiendo el orden Cálido, Templado y Frío.

Cuadro 3: *Matrices de confusión de los cinco algoritmos sobre el conjunto de prueba.*

Modelo	**Matriz (real × predicha)**		
	Cálido	Templado	Frío
Árbol de Decisión	668	0	0
	62	640	1
	0	164	655
Random Forest	665	3	0
	61	620	22
	0	68	751
SVM	666	2	0
	60	641	2
	0	196	623
K-NN	658	10	0
	41	624	38
	0	361	458
Naive Bayes	663	5	0
	49	654	0
	0	109	710

5 Discusión

Los resultados muestran que los modelos de ensamble y los métodos basados en supuestos probabilísticos alcanzaron el mejor desempeño. **Random Forest** y **Naive Bayes** obtuvieron F1-score macro superiores a 0,92, evidenciando una adecuada capacidad de generalización a ciudades no observadas durante el entrenamiento. Este hallazgo es coherente con la literatura, que reporta que los métodos de ensamble tienden a capturar de manera robusta relaciones no lineales entre las características (brevemente, la interdependencia entre altitud, coordenadas y estacionalidad) sin incurrir en el sobreajuste propio de un árbol individual (Hastie et al., 2009).

El menor desempeño de **K-NN** es igualmente explicable. Al apoyarse en la proximidad geométrica de las observaciones, este algoritmo es especialmente sensible a la estructura de los datos: al evaluarse sobre ciudades geográficamente distintas a las de entrenamiento, los vecinos más cercanos pueden no ser representativos de la clase verdadera, lo que se traduce en una degradación notable de la sensibilidad en la clase *frío* (recall = 0,56). De manera análoga, la clase *frío* resultó la más difícil de recuperar para SVM (recall = 0,76), lo que sugiere que la frontera de decisión radial no logró separar de forma óptima las regiones altitudinales extremas con el conjunto de datos disponibles.

Un aspecto central del presente trabajo es la **validez de las métricas reportadas**. A diferencia de una partición aleatoria por filas, que habría ubicado días de una misma ciudad en ambos conjuntos y, por tanto, inflado el rendimiento aparente, la división por ciudad obliga a los modelos a predecir sobre geografía genuinamente nueva. En consecuencia, los valores obtenidos (por ejemplo, un F1 macro de 0,9290 para Random Forest) constituyen una estimación más honesta y, en general, más baja que la que se habría obtenido con un muestreo aleatorio simple. Este resultado subraya la importancia de reconocer la estructura de agrupación de los datos antes de definir el esquema de validación.

Finalmente, la distinción entre la etiqueta operativa y el piso térmico geográfico oficial merece una reflexión. Al construir la variable objetivo a partir de la temperatura media diaria, un mismo punto geográfico puede cambiar de clase entre días distintos (por ejemplo, por una ola de calor o de frío). Por ello, los resultados de este ejercicio no deben interpretarse como una clasificación del piso térmico oficial de cada ciudad, sino como la evaluación de la capacidad de los algoritmos para predecir la condición térmica diaria a partir de información geográfica y temporal.

6 Conclusiones

A partir del trabajo realizado, se concluye lo siguiente:

1. Se construyó y documentó un problema de clasificación supervisada real y reproducible, basado en datos de temperatura media diaria de 26 ciudades colombianas obtenidos de

Open-Meteo (año 2023).

2. Se implementó un control explícito de la fuga de información mediante (a) una partición por ciudad con `GroupShuffleSplit`, que garantizó la ausencia de ciudades compartidas entre entrenamiento y prueba, y (b) un escalado ajustado exclusivamente con los datos de entrenamiento.
3. Se evaluaron cinco algoritmos en condiciones idénticas. **Random Forest** resultó el mejor modelo (F1-score macro = 0,9290), y **K-NN** el de menor rendimiento (F1-score macro = 0,7981).
4. La validación por grupos produjo estimaciones de desempeño más realistas que las que se obtendrían con una partición aleatoria por filas, lo que evidencia la necesidad de considerar la estructura de agrupación de los datos en el diseño experimental.
5. El uso de múltiples métricas (accuracy, precisión, recall y F1-score, con promedios macro y ponderado) permitió detectar debilidades específicas por clase que la exactitud global no habría revelado.

7 Referencias

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.

Instituto de Hidrología, Meteorología y Estudios Ambientales. (2023). *Clasificación climática de Colombia*. IDEAM.

Kaufman, S., Rosset, S., Perlich, C., y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21. `https://doi.org/10.1145/2382577.2382579`

Raschka, S. (2018). Model evaluation, model selection, and algorithm selection in machine learning. *arXiv preprint arXiv:1811.12808*. `https://arxiv.org/abs/1811.12808`